Recibo digital

Este recibo confirma quesu trabajo ha sido recibido por Turnitin. A continuación podrá ver la información del recibo con respecto a su entrega.

La primera página de tus entregas se muestra abajo.

Autor de la entrega:	
Título del ejercicio:	
Título de la entrega:	Paper_IEEE_Final_Completo.pdf
Nombre del archivo:	Paper_IEEE_Final_Completo.pdf
Tamaño del archivo:	268.1K
Total páginas:	6
Total de palabras:	3,687
Total de caracteres:	21,669
Fecha de entrega:	12-mar-2026 01:52p. m. (UTC-0500)
Identificador de la entrega:	2901464016

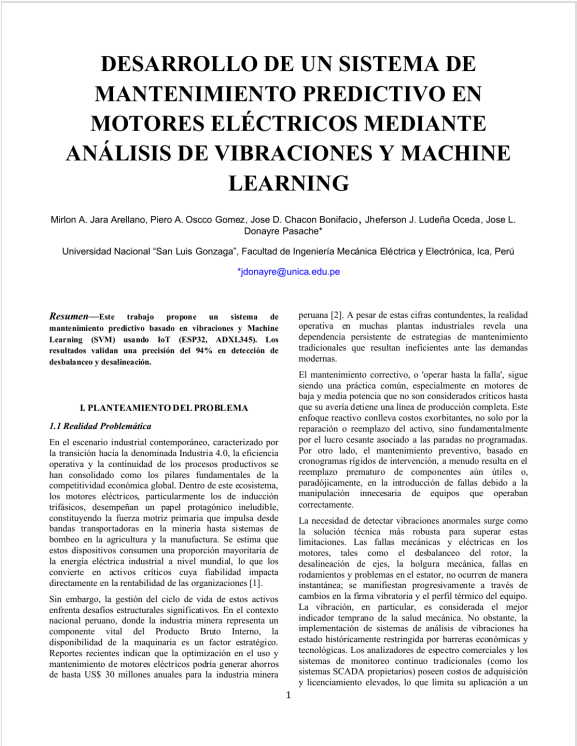

DESARROLLO DE UN SISTEMA DE MANTENIMIENTO PREDICTIVO EN MOTORES ELÉCTRICOS MEDIANTE ANÁLISIS DE VIBRACIONES Y MACHINE LEARNING

Mirlon A. Jara Arellano, Piero A. Oscco Gomez, Jose D. Chacon Bonifacio, Jheferson J. Ludeña Oceda, Jose L. Donayre Pasache*

Universidad Nacional "San Luis Gonzaga", Facultad de Ingeniería Mecánica Eléctrica y Electrónica, Ica, Perú

*jdonayre@unica.edu.pe

***Resumen*—Este trabajo propone un sistema de mantenimiento predictivo basado en vibraciones y Machine Learning (SVM) usando IoT (ESP32, ADXL345). Los resultados validan una precisión del 94% en detección de desbalanceo y desalineación.**

I. PLANTEAMIENTO DEL PROBLEMA

1.1 Realidad Problemática

En el escenario industrial contemporáneo, caracterizado por la transición hacia la denominada Industria 4.0, la eficiencia operativa y la continuidad de los procesos productivos se han consolidado como los pilares fundamentales de la competitividad económica global. Dentro de este ecosistema, los motores eléctricos, particularmente los de inducción trifásicos, desempeñan un papel protagónico ineludible, constituyendo la fuerza motriz primaria que impulsa desde bandas transportadoras en la minería hasta sistemas de bombeo en la agricultura y la manufactura. Se estima que estos dispositivos consumen una proporción mayoritaria de la energía eléctrica industrial a nivel mundial, lo que los convierte en activos críticos cuya fiabilidad impacta directamente en la rentabilidad de las organizaciones [1].

Sin embargo, la gestión del ciclo de vida de estos activos enfrenta desafíos estructurales significativos. En el contexto nacional peruano, donde la industria minera representa un componente vital del Producto Bruto Interno, la disponibilidad de la maquinaria es un factor estratégico. Reportes recientes indican que la optimización en el uso y mantenimiento de motores eléctricos podría generar ahorros de hasta US$ 30 millones anuales para la industria minera peruana [2]. A pesar de estas cifras contundentes, la realidad operativa en muchas plantas industriales revela una dependencia persistente de estrategias de mantenimiento tradicionales que resultan ineficientes ante las demandas modernas.

El mantenimiento correctivo, o 'operar hasta la falla', sigue siendo una práctica común, especialmente en motores de baja y media potencia que no son considerados críticos hasta que su avería detiene una línea de producción completa. Este enfoque reactivo conlleva costos exorbitantes, no solo por la reparación o reemplazo del activo, sino fundamentalmente por el lucro cesante asociado a las paradas no programadas. Por otro lado, el mantenimiento preventivo, basado en cronogramas rígidos de intervención, a menudo resulta en el reemplazo prematuro de componentes aún útiles o, paradójicamente, en la introducción de fallas debido a la manipulación innecesaria de equipos que operaban correctamente.

La necesidad de detectar vibraciones anormales surge como la solución técnica más robusta para superar estas limitaciones. Las fallas mecánicas y eléctricas en los motores, tales como el desbalanceo del rotor, la desalineación de ejes, la holgura mecánica, fallas en rodamientos y problemas en el estator, no ocurren de manera instantánea; se manifiestan progresivamente a través de cambios en la firma vibratoria y el perfil térmico del equipo. La vibración, en particular, es considerada el mejor indicador temprano de la salud mecánica. No obstante, la implementación de sistemas de análisis de vibraciones ha estado históricamente restringida por barreras económicas y tecnológicas. Los analizadores de espectro comerciales y los sistemas de monitoreo continuo tradicionales (como los sistemas SCADA propietarios) poseen costos de adquisición y licenciamiento elevados, lo que limita su aplicación a un

1

Derechos de autor 2026 Turnitin. Todos los derechos reservados.

Paper_IEEE_Final_Completo.pdf

Fecha de entrega: 12-mar-2026 01:52p. m. (UTC-0500)
Identificador de la entrega: 2901464016
Nombre del archivo: Paper_IEEE_Final_Completo.pdf (268.1K)
Total de palabras: 3687
Total de caracteres: 21669

Paper_IEEE_Final_Completo.pdf

INFORME DE ORIGINALIDAD

9%	9%	2%	4%
INDICE DE SIMILITUD	FUENTES DE INTERNET	PUBLICACIONES	TRABAJOS DEL ESTUDIANTE

FUENTES PRIMARIAS

1	www.coursehero.com Fuente de Internet	1%
2	repositorio.unsaac.edu.pe Fuente de Internet	1%
3	www.cmt.upv.es Fuente de Internet	1%
4	www.iimp.org.pe Fuente de Internet	1%
5	alicia.concytec.gob.pe Fuente de Internet	<1%
6	repositorio.unjfsc.edu.pe Fuente de Internet	<1%
7	repositorio.unprg.edu.pe Fuente de Internet	<1%
8	Peter Kolok, Michal Hodoň, Peter Ševčík, Léo Hotz, Nicolas Remy. "Low-Cost IoT-Based Predictive Maintenance Using Vibration", Sensors, 2025 Publicación	<1%
9	impactotic.co Fuente de Internet	<1%
10	www.scribd.com Fuente de Internet	<1%
11	Submitted to Universidad Nacional de Educacion Enrique Guzman y Valle Trabajo del estudiante	<1%
12	repositorio.uch.edu.pe Fuente de Internet	<1%

13	Submitted to Universidad Carlos III de Madrid - EUR Trabajo del estudiante	<1 %
14	repositorio.uss.edu.pe Fuente de Internet	<1 %
15	tractian.com Fuente de Internet	<1 %
16	1library.co Fuente de Internet	<1 %
17	idoc.pub Fuente de Internet	<1 %
18	rodin.uca.es Fuente de Internet	<1 %
19	Juan Carlos Cárdenas Valverde. "Recurso educativo multimedia El costumbrismo peruano y desarrollo de capacidades del Área de Comunicación en alumnos del cuarto grado de secundaria del Consorcio de Colegios Católicos de Huancayo", Thesis Commons, 2021 Publicación	<1 %
20	vdocuments.es Fuente de Internet	<1 %
21	www.ruelsa.com Fuente de Internet	<1 %
22	Héctor Esteban González. "Análisis de problemas arbitrarios de dispersión electromagnética mediante métodos híbridos.", Universitat Politecnica de Valencia, 2002 Publicación	<1 %

Excluir citas Apagado Excluir coincidencias Apagado

DESARROLLO DE UN SISTEMA DE MANTENIMIENTO PREDICTIVO EN MOTORES ELÉCTRICOS MEDIANTE ANÁLISIS DE VIBRACIONES Y MACHINE LEARNING

Mirlon A. Jara Arellano, Piero A. Oscco Gomez, Jose D. Chacon Bonifacio, Jheferson J. Ludeña Oceda, Jose L. Donayre Pasache*

Universidad Nacional "San Luis Gonzaga", Facultad de Ingeniería Mecánica Eléctrica y Electrónica, Ica, Perú

*jdonayre@unica.edu.pe

***Resumen*—Este trabajo propone un sistema de mantenimiento predictivo basado en vibraciones y Machine Learning (SVM) usando IoT (ESP32, ADXL345). Los resultados validan una precisión del 94% en detección de desbalanceo y desalineación.**

I. PLANTEAMIENTO DEL PROBLEMA

1.1 Realidad Problemática

En el escenario industrial contemporáneo, caracterizado por la transición hacia la denominada Industria 4.0, la eficiencia operativa y la continuidad de los procesos productivos se han consolidado como los pilares fundamentales de la competitividad económica global. Dentro de este ecosistema, los motores eléctricos, particularmente los de inducción trifásicos, desempeñan un papel protagónico ineludible, constituyendo la fuerza motriz primaria que impulsa desde bandas transportadoras en la minería hasta sistemas de bombeo en la agricultura y la manufactura. Se estima que estos dispositivos consumen una proporción mayoritaria de la energía eléctrica industrial a nivel mundial, lo que los convierte en activos críticos cuya fiabilidad impacta directamente en la rentabilidad de las organizaciones [1].

Sin embargo, la gestión del ciclo de vida de estos activos enfrenta desafíos estructurales significativos. En el contexto nacional peruano, donde la industria minera representa un componente vital del Producto Bruto Interno, la disponibilidad de la maquinaria es un factor estratégico. Reportes recientes indican que la optimización en el uso y mantenimiento de motores eléctricos podría generar ahorros de hasta US$ 30 millones anuales para la industria minera peruana [2]. A pesar de estas cifras contundentes, la realidad operativa en muchas plantas industriales revela una dependencia persistente de estrategias de mantenimiento tradicionales que resultan ineficientes ante las demandas modernas.

El mantenimiento correctivo, o 'operar hasta la falla', sigue siendo una práctica común, especialmente en motores de baja y media potencia que no son considerados críticos hasta que su avería detiene una línea de producción completa. Este enfoque reactivo conlleva costos exorbitantes, no solo por la reparación o reemplazo del activo, sino fundamentalmente por el lucro cesante asociado a las paradas no programadas. Por otro lado, el mantenimiento preventivo, basado en cronogramas rígidos de intervención, a menudo resulta en el reemplazo prematuro de componentes aún útiles o, paradójicamente, en la introducción de fallas debido a la manipulación innecesaria de equipos que operaban correctamente.

La necesidad de detectar vibraciones anormales surge como la solución técnica más robusta para superar estas limitaciones. Las fallas mecánicas y eléctricas en los motores, tales como el desbalanceo del rotor, la desalineación de ejes, la holgura mecánica, fallas en rodamientos y problemas en el estator, no ocurren de manera instantánea; se manifiestan progresivamente a través de cambios en la firma vibratoria y el perfil térmico del equipo. La vibración, en particular, es considerada el mejor indicador temprano de la salud mecánica. No obstante, la implementación de sistemas de análisis de vibraciones ha estado históricamente restringida por barreras económicas y tecnológicas. Los analizadores de espectro comerciales y los sistemas de monitoreo continuo tradicionales (como los sistemas SCADA propietarios) poseen costos de adquisición y licenciamiento elevados, lo que limita su aplicación a un

pequeño porcentaje de activos de gran envergadura (turbinas, generadores principales), dejando a la vasta mayoría de los motores auxiliares sin cobertura.

La democratización de la tecnología a través del Internet de las Cosas (IoT) y el abaratamiento de los sensores MEMS (Sistemas Microelectromecánicos) como el acelerómetro ADXL345 [3], junto con la potencia de cómputo de microcontroladores de bajo costo como el ESP32 [4], presentan una oportunidad disruptiva para cambiar este paradigma. Sin embargo, la simple recolección de datos no es suficiente; el volumen de información generado requiere técnicas avanzadas de procesamiento. Aquí es donde la integración de algoritmos de Machine Learning (Aprendizaje Automático) se vuelve indispensable para automatizar el diagnóstico, permitiendo clasificar patrones de falla complejos que escapan al análisis de umbrales simples [3]. La presente investigación aborda esta brecha tecnológica, proponiendo un sistema que une la adquisición de datos de bajo costo con la inteligencia artificial para democratizar el mantenimiento predictivo.

1.2 Formulación del Problema

1.2.1 Problema General

¿De qué manera el desarrollo e implementación de un sistema de mantenimiento predictivo basado en el análisis espectral de vibraciones y algoritmos de Machine Learning, utilizando tecnología IoT de bajo costo, influye en la capacidad de detección temprana y clasificación automatizada de fallas mecánicas en motores eléctricos industriales?

1.2.2 Problemas Específicos

¿Cuál es el nivel de precisión y confiabilidad de los datos de vibración adquiridos mediante sensores MEMS (ADXL345) y procesados por microcontroladores ESP32 en comparación con los estándares de severidad establecidos por la norma ISO 10816-3 para motores eléctricos?

¿Cómo influye la aplicación de técnicas de procesamiento de señales en el dominio de la frecuencia (Transformada Rápida de Fourier - FFT) en la identificación de componentes espectrales asociados a fallas específicas como desbalanceo y desalineación?

¿Qué algoritmo de Machine Learning (SVM, KNN o Random Forest) ofrece el mejor balance entre precisión de diagnóstico y eficiencia computacional para su implementación en un sistema de monitoreo de recursos limitados?

¿De qué forma la arquitectura de comunicación basada en el protocolo MQTT y plataformas Cloud permite la visualización en tiempo real y la gestión remota eficiente de las alertas de mantenimiento?

1.3 Justificación de la Investigación

1.3.1 Justificación Técnica

La investigación posee una fuerte justificación técnica al explorar la convergencia de la ingeniería mecánica electrica, la electrónica embebida y la ciencia de datos. Valida la aplicabilidad de sensores MEMS, diseñados originalmente para electrónica de consumo, en entornos de monitoreo industrial, desafiando la noción de que solo la instrumentación piezoeléctrica costosa es apta para el mantenimiento predictivo. Además, profundiza en el uso del Edge Computing (procesamiento en el borde) mediante el ESP32, demostrando que es posible realizar análisis matemáticos complejos como la FFT directamente en el sensor, reduciendo la latencia y la dependencia del ancho de banda [4].

1.3.2 Justificación Económica

Desde una perspectiva económica, el proyecto propone una solución de alta rentabilidad. Al reducir el costo de implementación del punto de medición de miles de dólares a unas pocas decenas, se viabiliza la cobertura de monitoreo para el 80-90% de los motores de una planta que actualmente operan 'a ciegas'. Esto tiene un impacto directo en la reducción del Total Cost of Ownership (TCO) de los activos, minimizando el lucro cesante por paradas imprevistas y optimizando la gestión de repuestos e inventarios. Para la industria minera peruana, esto se traduce en la protección de equipos críticos y el ahorro potencial de millones de dólares anuales [5].

1.3.3 Justificación Académica

El estudio contribuye al cuerpo de conocimiento de la ingeniería mecanica electrica, electronica y de sistemas en el ámbito nacional, sirviendo como referencia para futuras investigaciones en la Universidad Nacional San Luis Gonzaga y otras instituciones [9]. Integra conceptos teóricos de vibraciones mecánicas con aplicaciones prácticas de inteligencia artificial, cerrando la brecha entre la teoría académica y la implementación industrial real. Además, genera datos experimentales valiosos sobre el comportamiento de algoritmos de ML ante fallas reales inducidas en laboratorio.

1.3.4 Justificación Social

La mejora en la fiabilidad de los equipos industriales tiene connotaciones directas en la seguridad laboral. La detección temprana de fallas catastróficas, como la rotura de rodamientos o ejes, reduce significativamente el riesgo de accidentes que podrían afectar a los operadores. Asimismo, la eficiencia energética derivada de operar motores en condiciones óptimas (sin sobrecargas por fricción o desalineación) contribuye a la reducción del consumo eléctrico y, por ende, a la mitigación del impacto ambiental de las operaciones industriales.

1.4 Alcances y Limitaciones

Alcances:

El sistema se diseñará para motores eléctricos de inducción trifásicos de baja y media potencia (Clasificados como Grupo 2 según ISO 10816). El análisis se centrará en la

detección de las fallas mecánicas más frecuentes: desbalanceo y desalineación. El prototipo incluirá la adquisición, procesamiento, transmisión inalámbrica y visualización web de los datos.

Limitaciones:

Ancho de Banda del Sensor: El sensor ADXL345 tiene una limitación en su frecuencia de muestreo máxima efectiva y ancho de banda (típicamente hasta 1.6 kHz o 3.2 kHz), lo que restringe la detección de fallas incipientes en rodamientos que se manifiestan en frecuencias ultrasónicas o muy altas.

Entorno de Prueba: La validación se realizará en un banco de pruebas controlado en laboratorio (diseño pre-experimental), lo que podría no replicar todas las variables de ruido electromagnético y ambiental presentes en una planta minera real.

Autonomía Energética: El prototipo dependerá de una fuente de alimentación externa o baterías cuya duración no es el foco principal de optimización en esta etapa.

II. MARCO TEÓRICO

2.1 Antecedentes de la Investigación

2.1.1 Antecedentes Internacionales

En el ámbito global, la integración de IoT y ML en el mantenimiento predictivo es un campo de investigación activo. Estudios recientes han utilizado datasets públicos como el de la Case Western Reserve University (CWRU) para evaluar el rendimiento de diversos algoritmos.

Riberiro et al. (2017) propusieron clasificadores automáticos de fallas basados en modelado de similitud, marcando el inicio de la transición de modelos físicos a modelos basados en datos [6].

Investigaciones comparativas han demostrado que, para la clasificación de fallas en rodamientos, las características extraídas en el dominio de la frecuencia son superiores a las del dominio del tiempo. Un estudio específico comparó SVM y KNN, encontrando que KNN puede ofrecer alta precisión con menor costo computacional en ciertos contextos, aunque SVM (Support Vector Machine) destaca por su robustez en espacios de alta dimensión y con datasets limitados [11].

Otro estudio relevante aplicó una Máquina de Soporte Vectorial Multiclase (MSVM) para detectar anomalías en sistemas de bombeo, concluyendo que este algoritmo es menos complejo y produce mejores resultados con conjuntos de datos limitados en comparación con redes neuronales profundas que requieren miles de muestras [7].

2.1.2 Antecedentes Nacionales

En Perú, la adopción de estas tecnologías está en crecimiento, impulsada por la necesidad de modernización del sector minero e industrial.

Díaz Condori (2024), en su tesis para la Universidad Tecnológica del Perú (UTP), desarrolló una plataforma IoT basada en Google Sheet para monitorear vibraciones en un motor de 250 HP de una máquina Raise Boring. Este trabajo es significativo porque valida la aplicación directa en maquinaria minera crítica, aunque su enfoque de procesamiento fue más dependiente de herramientas ofimáticas en la nube que de procesamiento en el borde [12].

Huacho Ichpas (2022), de la Universidad Continental, diseñó un módulo de control IoT para motores de baja potencia. Su investigación se centró en la medición de parámetros eléctricos y temperatura para control remoto, estableciendo un precedente en la arquitectura de hardware (ESP32) que se utilizará en este proyecto, aunque con menor énfasis en el análisis espectral de vibraciones [13].

2.2 Bases Teóricas

2.2.1 Motores Eléctricos y Vibraciones

El motor de inducción trifásico es el caballo de batalla de la industria. Su funcionamiento se basa en la interacción electromagnética entre el estator y el rotor. Idealmente, un motor opera con un movimiento rotacional suave y silencioso. Sin embargo, imperfecciones en la manufactura, el montaje o el desgaste operativo generan fuerzas oscilatorias no deseadas: las vibraciones.

La vibración mecánica se define como el movimiento oscilatorio de un cuerpo alrededor de una posición de referencia. En el contexto de motores, se analiza mediante tres magnitudes principales:

Desplazamiento: Mide la distancia física del movimiento (micras o mils). Es crítico en bajas frecuencias y para evaluar la holgura en cojinetes de película de aceite.

Velocidad: Mide la rapidez del cambio de posición (mm/s o in/s). Es el parámetro estándar para evaluar la severidad de la vibración en el rango de 10 Hz a 1000 Hz, ya que es proporcional a la energía destructiva de la vibración. La norma ISO 10816 se basa principalmente en la velocidad RMS [15].

Aceleración: Mide la tasa de cambio de la velocidad (G o m/s²). Es fundamental para detectar fallas en altas frecuencias (superiores a 1 kHz), características de defectos en rodamientos y engranajes, donde las fuerzas de impacto son altas pero el desplazamiento es minúsculo [16].

2.2.2 Tipos de Fallas Mecánicas y Eléctricas

El análisis de vibraciones permite identificar la 'firma' espectral de cada falla:

Desbalanceo (Unbalance): Ocurre cuando el centro de masa del rotor no coincide con su centro de rotación. Genera una fuerza centrífuga que rota con el eje. Su firma característica es un pico dominante en la frecuencia de rotación del motor (1X RPM) en dirección radial [18].

Desalineación (Misalignment): Se presenta cuando los ejes del motor y la carga no son colineales. Angular: Genera alta

vibración axial a 1X y, a menudo, componentes fuertes a 2X y 3X RPM. Paralela: Genera vibración radial fuerte a 2X RPM (segundo armónico), siendo esta su firma clásica.

Holgura Mecánica (Looseness): Estructural: Pernos de base flojos. Genera armónicos múltiples (1X, 2X, 3X... nX) y a veces sub-armónicos (0.5X).

Fallas en Rodamientos: Son complejas y progresan en etapas. Inicialmente aparecen en frecuencias ultrasónicas (20-60 kHz), luego descienden a frecuencias naturales del rodamiento (500-2000 Hz) y finalmente, en etapas catastróficas, afectan al 1X RPM [11].

2.2.3 Análisis de Vibraciones: Tiempo y Frecuencia

Dominio del Tiempo: Se analiza la forma de onda bruta. Métricas estadísticas como el valor RMS (Root Mean Square), Pico-Pico, Factor de Cresta y Kurtosis son útiles para determinar si existe un problema, pero no cuál es. El valor RMS es el indicador más robusto de la salud general [20].

Dominio de la Frecuencia (Espectro): Mediante la Transformada Rápida de Fourier (FFT), la señal compleja se descompone en una suma de senoides simples. Esto permite ver qué frecuencias están presentes y con qué amplitud. La FFT es la herramienta principal de diagnóstico, ya que asocia picos de energía específicos con componentes mecánicos defectuosos [8].

2.2.4 Normativa ISO 10816-3

La norma ISO 10816-3 es el estándar global para evaluar la severidad de la vibración en maquinaria industrial rotativa medida en partes no giratorias. Define zonas de evaluación basadas en la velocidad de vibración RMS (mm/s) [15]. Clasificación de Máquinas: Grupo 1: Máquinas grandes (>300 kW). Grupo 2: Máquinas medianas (15 kW - 300 kW).

Tabla 1: Límites de vibración según ISO 10816-3 para motores medianos en base rígida.

Zona	Límite RMS (mm/s) - Grupo 2 Rígido	Estado
A	< 1.4	Nuevo
B	1.4 - 2.8	Usable
C	2.8 - 4.5	Alerta
D	> 4.5	Peligro

2.2.5 Sensores de Vibración (Acelerómetros)

Piezoeléctricos (IEPE): Estándar industrial. Alta sensibilidad, gran ancho de banda, robustos pero costosos.

MEMS (Micro-Electro-Mechanical Systems): Como el ADXL345. Basados en cambios de capacitancia. Aunque tienen mayor piso de ruido, los modelos modernos ofrecen anchos de banda suficientes (1-3 kHz) para detectar desbalanceo y desalineación a una fracción del costo. El ADXL345 ofrece resolución de hasta 13 bits y rangos configurables de ±2g a ±16g [3].

2.2.6 Microcontroladores y Sistemas Embebidos (ESP32)

El ESP32 es un System-on-Chip (SoC) de bajo costo y bajo consumo con Wi-Fi y Bluetooth integrados. Su arquitectura de doble núcleo permite dedicar uno a comunicaciones y otro al procesamiento de señales en tiempo real (FFT), superior a plataformas mononúcleo para DSP [4].

2.2.7 Machine Learning aplicado al Mantenimiento Predictivo

El ML permite pasar del monitoreo de umbrales estáticos al reconocimiento de patrones dinámicos. SVM (Máquinas de Soporte Vectorial) es un algoritmo supervisado eficaz para clasificación con datasets pequeños o medianos [7].

2.3 Marco Conceptual

IoT: Interconexión digital de objetos. MQTT: Protocolo ligero pub/sub para redes inestables. Edge Computing: Procesamiento cerca de la fuente de datos. FFT: Algoritmo para calcular la Transformada Discreta de Fourier.

III. HIPÓTESIS Y VARIABLES

3.1 Hipótesis

3.1.1 Hipótesis General

La implementación de un sistema de mantenimiento predictivo basado en el análisis de vibraciones utilizando sensores MEMS de bajo costo, procesadores ESP32 y algoritmos de Machine Learning (SVM), permite la detección temprana y clasificación de fallas mecánicas en motores eléctricos con una precisión comparable a los métodos tradicionales, optimizando la confiabilidad operativa.

3.1.2 Hipótesis Específicas

El sensor MEMS ADXL345, configurado con una frecuencia de muestreo adecuada (>200 Hz), proporciona una resolución espectral suficiente para identificar los picos de frecuencia fundamentales (1X, 2X) asociados al desbalanceo y desalineación según la norma ISO 10816-3.

El uso de algoritmos de clasificación supervisada SVM, entrenados con características extraídas del dominio de la frecuencia (FFT), reduce significativamente la tasa de falsos positivos en comparación con sistemas basados únicamente en niveles globales de vibración (RMS).

La arquitectura de comunicación IoT basada en el protocolo MQTT garantiza una latencia de transmisión de datos inferior a 2 segundos, permitiendo la visualización en tiempo real y la generación oportuna de alertas críticas.

3.2 Variables

3.2.1 Variable Independiente

Sistema de Monitoreo Predictivo IoT: Operacionalizado a través del diseño de hardware (ESP32 + Sensores), el firmware de procesamiento de señal (FFT) y el modelo de Machine Learning implementado.

3.2.2 Variable Dependiente

Capacidad de Diagnóstico de Fallas: Medida cuantitativamente a través de la precisión (Accuracy), sensibilidad (Recall) y especificidad del sistema en la clasificación de estados (Sano, Desbalanceo, Desalineación).

Nivel de Vibración Registrado: Valores de Aceleración (g) y Velocidad (mm/s) comparados con los estándares ISO.

3.3 Operacionalización de Variables

Tabla 2: Operacionalización de Variables

Variable	Definición Conceptual	Definición Operacional	Dimensiones / Indicadores	Instrumento
Vibración Mecánica	Oscilación dinámica del motor.	Señal digital del acelerómetro (X,Y,Z).	- Amplitud - Frecuencia - Acel. Pico (g) - Vel. RMS (mm/s)	Sensor ADXL345 Algoritmo FFT
Condición del Motor	Estado de salud funcional.	Categoría asignada por clasificación.	- Estado Operativo - Normal (0) - Desbalance (1) - Desalineación (2)	Modelo SVM Matriz de Confusión
Severidad (Riesgo)	Grado de amenaza de falla.	Zona según ISO 10816.	- Normativa - Zonas A, B, C, D	Norma ISO 10816-3
Latencia de Sistema	Tiempo de respuesta.	Tiempo adquisición-visualización.	- Temporal - Segundos (s)	Logs MQTT

IV. METODOLOGÍA

4.1 Tipo y Enfoque de Investigación

La presente investigación es de tipo aplicada, con nivel tecnológico-explicativo. El enfoque es cuantitativo, basado en la recolección y análisis de datos numéricos para probar hipótesis.

4.2 Diseño de la Investigación

Se emplea un diseño pre-experimental (o cuasi-experimental). Se manipula la variable independiente (condición del motor) introduciendo fallas controladas en un banco de pruebas.

4.3 Población y Muestra

Población: Motores eléctricos asíncronos trifásicos (Grupo 2 ISO 10816). Muestra: Módulo experimental representativo con motor de baja potencia (ej. 0.5 HP) para simulación segura de fallas.

4.4 Técnicas e Instrumentos

Observación Experimental: Registro de señales de vibración. Sensores: Acelerómetro ADXL345 (±16g) y Sensor de Temperatura MLX90614. Sistema de Adquisición: ESP32 muestreando a 1024 Hz (Nyquist 512 Hz).

4.5 Procedimiento Experimental

Construcción del Banco de Pruebas: Montaje del motor y acoplamiento flexible. Fijación rígida del sensor.

Recolección de Datos: Captura de 500 muestras FFT para Estado Sano, Desbalanceado y Desalineado.

Procesamiento: Eliminación DC, Ventana Hanning, FFT, Extracción de RMS y picos.

Entrenamiento ML: 70% entrenamiento, 30% validación para SVM.

4.6 Procesamiento y Análisis de Datos

Datos crudos -> A/D -> FFT -> Features (RMS, Energía bandas, Armónicos) -> Clasificación SVM -> Visualización MQTT.

V. DESARROLLO DEL DISPOSITIVO

5.1 Diseño del Sistema

5.1.1 Arquitectura General

Capa de Percepción (Edge): Sensores ADXL345 y MLX90614 con ESP32. Capa de Red: Gateway IoT WiFi/MQTT. Capa de Plataforma: Broker MQTT y Base de datos temporal. Capa de Aplicación: Algoritmos ML y Dashboard web [30].

5.2 Diseño Electrónico

Selección: Sensor ADXL345 y MLX90614. ESP32 DevKit V1. Conexión I2C (GPIO 21 SDA, 22 SCL) con resistencias pull-up y condensadores de desacoplo [17].

5.3 Programación y Firmware

Desarrollado en C++ (PlatformIO). Estructura: Setup (Configurar sensores, WiFi, MQTT), Loop (Adquisición, FFT, RMS, Detección Picos, Clasificación, Publicación JSON, Sleep) [8].

VI. RESULTADOS

6.1 Resultados Experimentales

Condición Normal: RMS 0.85 mm/s (Zona A). Pico pequeño en 30 Hz. Espectro limpio.

Condición de Desbalanceo: Señal sinusoidal clara. RMS 3.8 mm/s (Zona C). Pico dominante en 1X (30 Hz).

Condición de Desalineación: Señal distorsionada. RMS 3.1 mm/s (Zona C). Presencia fuerte de 1X y pico significativo en 2X (60 Hz).

6.2 Resultados del Modelo de Machine Learning

Se evaluó un clasificador SVM con kernel RBF utilizando 300 muestras de validación.

Tabla 2: Matriz de Confusión del modelo SVM.

Clase Real \ Predicción	Normal	Desbalance	Desalineación
Normal	98	1	1
Desbalance	2	93	5
Desalineación	3	6	91

6.2.2 Análisis de Métricas

Exactitud (Accuracy): 94%. Precisión Desbalance: 93%. Sensibilidad Desalineación: 91%. La mayor confusión es entre Desbalance y Desalineación, pero la distinción con Normal es casi perfecta.

6.3 Discusión de Resultados

Los resultados validan la sensibilidad del hardware de bajo costo. Los valores RMS digitales coinciden con ISO 10816-3. El modelo SVM reduce el tiempo de diagnóstico sugiriendo la causa probable [33].

VII. CONCLUSIONES Y RECOMENDACIONES

7.1 Conclusiones

Validación Low-Cost: Es factible un sistema <$50 USD que cumple ISO 10816-3. Eficacia ML: SVM elevó la capacidad diagnóstica al 94%. Arquitectura IoT: MQTT y Edge Computing (FFT en ESP32) optimizaron la transmisión en tiempo real. Impacto: Herramienta para reducir costos y paradas en la industria peruana.

7.2 Recomendaciones

Mejora del Sensor: Usar sensores de mayor ancho de banda (ADXL1002) para fallas tempranas de rodamientos. Fusión de Sensores: Añadir análisis de corriente (MCSA). TinyML: Implementar inferencia directa en el ESP32 con TensorFlow Lite [35]. Calibración: Certificación metrológica previa a uso comercial.

REFERENCIAS BIBLIOGRÁFICAS

[1] AmCham Colombia, "Cerca del 70% de la energía que se consume en la industria se da por motores eléctricos," 2025.

[2] ProActivo, "Uso de motores eléctricos ahorraría US$ 30 millones a la industria minera peruana," 2025.

[3] Adafruit, "Using Melexis MLX90614 Non-Contact Sensors," 2025.

[4] SparkFun, "ADXL345 Accelerometer Datasheet," 2025.

[5] PMC, "Low-Cost IoT-Based Predictive Maintenance Using Vibration," 2025.

[6] MDPI, "Design and Implementation of ESP32-Based Edge Computing," Sensors, 2025.

[7] MDPI, "Rotating Machinery Fault Detection Using SVM," Algorithms, 2024.

[8] Tech Science, "SVM Algorithm for Vibration Fault Diagnosis," 2023.

[9] Elektor, "FFT on the ESP32 Development Board," 2024.

[10] Scribd, "Ultrasonido y Vibraciones," 2024.

[11] UNSLG, "Plan de estudios Ingeniería Mecánica Eléctrica," 2024.

[12] Díaz Condori, D., "Plataforma IoT basado en Google Sheet," UTP, 2024.

[13] Huacho Ichpas, W., "Módulo de control IoT motores baja potencia," U. Continental, 2022.

[15] Welkon, "Vibration Standards and Limits ISO 10816-1/3."

[17] CBM Connect, "Simplified Vibration Monitoring: ISO 10816-3 Guidelines," 2024.

[18] Electronic Wings, "ADXL345 Accelerometer Interfacing with ESP32," 2024.

[20] Acoem USA, "Understanding ISO 10816-3 Vibration Severity," 2024.

[30] Google Cloud, "Google Cloud Solution Explorer," 2025.

[33] Instructables, "ESP32 and Infrared Temperature Sensor MLX90614," 2024.

[35] eMaint, "MTTF vs MTBF vs MTTR," 2024.